Gruppuppgift – R-programmering för dataanalys

E-handel

Grupp 2

Henrik Andersson
Nadine Knoop
Milda Kopmane
Azar Mohseni
Henry Che

Case och syfte

Case

- Vi analyserar orderdata från en e-handelsverksamhet.
- Fokus ligger på försäljning, kundgrupper och skillnader mellan regioner.
- Analysen ska ge ett enkelt och användbart beslutsunderlag.

Syfte

- Identifiera mönster i försäljning mellan produktkategorier, kundsegment och regioner.
- Visa analysen tydligt med statistik och visualiseringar i R.
- Besvara våra frågeställningar med hjälp av beskrivande statistik och visualiseringar.

Kort om datasetet

1000
observationer

16
variabler

3 datatyper
kategorigska · numeriska · datumvariabler

5 variabler
med saknade värden

Vad datasetet innehåller

- **Orderinformation**: order_id och order_date
- **Kundinformation**: customer_id, customer_segment och customer_type
- **Produktinformation**: product_category, product_subcategory
- **Försäljningsinformation**: quantity, unit_price, discount_pct
- **Övrigt**: region, ctity, payment_method, campaign_source, shipping_days, returned

Viktiga variabler i analysen

- **Produktkategori**: product_category
- **Kundsegment**: customer_segment
- **Region**: region
- **Försäljning**: quantity, unit_price och discount_pct, order_value (skapad variabel)
- **Leveranstid**: shipping_days
- **Saknade värden**: city, payment_method, campaign_source, discount_pct och shipping_days

Valda frågeställningar

Fokus på ordervärde och försäljning

1. Vilka produktkategorier verkar driva högst försäljning?
2. Hur skiljer sig ordervärde mellan olika kundsegment?
3. Hur skiljer sig försäljning mellan olika regioner?

Datastädning och förberedelse

Datastädning

- Rensa och standardisera text och kategorier (str_trim, str_to_title)
- Konverterade datum till korrekt format (as.Date)
- Omvandlade kategoriska variabler till faktorer (as.factor)

Saknade värden

- Kategoriska variabler -> ersattes med *“Unknown”*
- Numeriska variabler -> ersattes med medianvärde

Nya variabler

- **order_value** = quantity * unit_price * (1 - discount_pct)
- **order_size** = case_when(
  order_value < 100 ~ "Low",
  order_value < 300 ~ "Medium",
  TRUE ~ "High")

Viktiga resultat från analysen

Produktkategorier (total försäljning)

1. *Electronics* (155500)
2. *Home* (60435)
3. *Sports* (54268)

Kundsegment

- *Consumer* – **mest total** försäljning (170338) och flest köp i alla orderstorlekar (Low, Medium, High)
- *Small Business* – spenderar **mest per köp** (346)
- Corporate – minst både antal ordar (169) och total försäljning (39744); och minst I alla orderstorlekar

Regioner

- *North* - högst försäljning (37.1%) och flest ordrar (354)
- *East* - högst ordervärde per köp (337)
- *South* - säljer minst (16.9%) och lägre värde (277) köp

Visualiseringar

Produktkategorier (total försäljning)

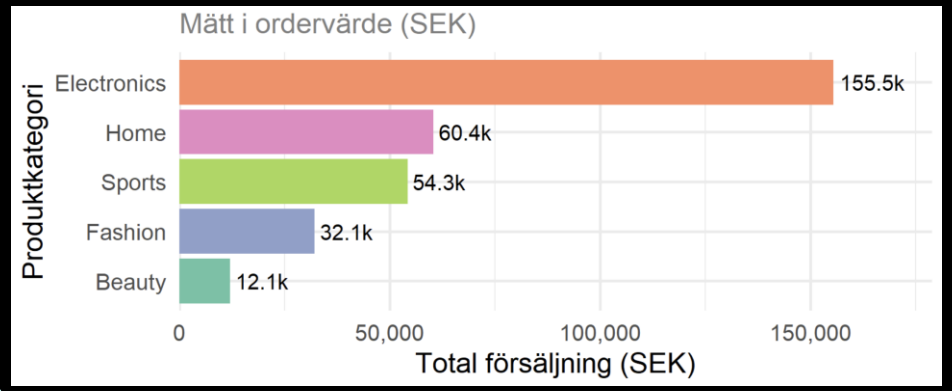

Ordervärde per kundsegment

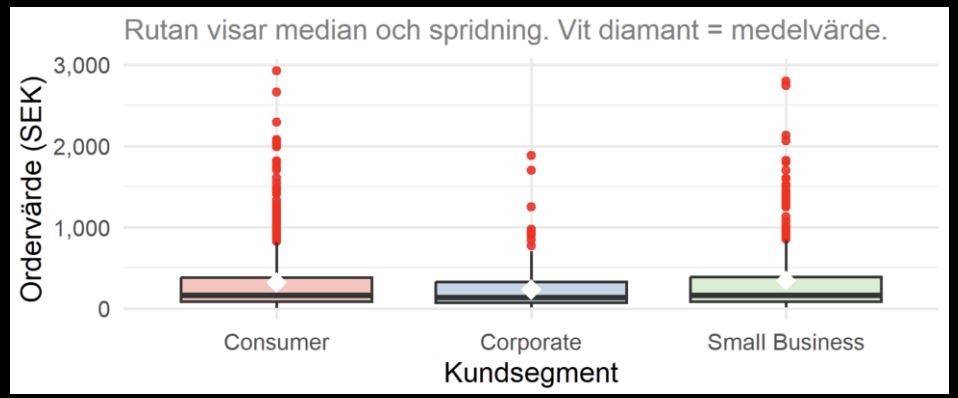

Regioner (total försäljning)

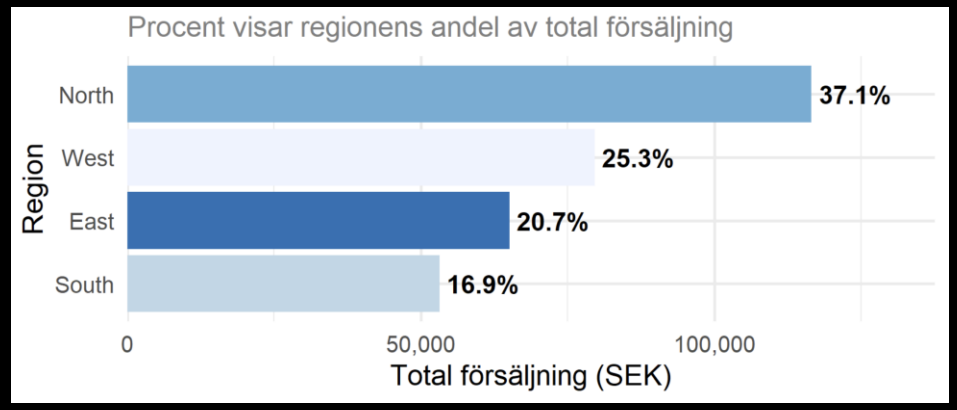

Sammanfattning

- Vi har beräknat statistiska sammanfattningar för att jämföra försäljning.
- Mellan produktkategorier, kundsegment och regioner.
- Electronics och Consumer står för den största delen av försäljningen.
- Small Business spenderar mest per köp.
- North är den starkaste regionen, medan South säljer minst.

Begränsningar

- Analysen bygger på ett dataset med 1000 ordrar och visar därför bara mönster i detta urval.
- Vissa värden saknades i datan och har ersatts vid datastädningen, vilket kan påverka resultaten något(bias).
- Analysen är baserad på historiska data och kan inte förutsäga framtida trender eller förändringar i kundbeteende.

Förslag på nästa steg

- Bygga vidare på denna analys
- Samla in mer data över en längre tidsperiod för att identifiera trende.
- Genomföra mer avancerade analyser, såsom klusteranalys eller prediktiv modellering, för att bättre förstå kundsegment och förutsäga framtida försäljning.